

دانشکده علوم ریاضی
گروه آمار

سامانه پیش‌بینی آب و هوا WFS Dashboard

ارزیابی و مقایسه مدل‌های یادگیری ماشین و آماری
در پیش‌بینی سری‌های زمانی هواشناسی

توسعه‌دهنده

مهدیه ابراهیمی

استاد راهنما

دکتر محمد آرشی

نیمسال دوم سال تحصیلی ۱۴۰۴-۱۴۰۵

فهرست مطالب

۲	۱ مقدمه و صورت مسئله
۲	۱.۱ زمینه و انگیزه پژوهش
۲	۲.۱ صورت مسئله و چالش‌های مدل‌های داده‌محور
۲	۳.۱ رویکرد سیستم: ارتقا تا مرز فیزیک
۳	۲ نمای کلی سامانه
۴	۳ الزامات سیستم (System Requirements)
۴	۱.۳ الزامات عملکردی (Functional Requirements)
۴	۲.۳ الزامات غیرعملکردی (Non-Functional Requirements)
۴	۴ مدل داده و مهندسی ویژگی
۴	۱.۴ پاکسازی پیشرفته و حذف نویز
۵	۲.۴ قیود فیزیکی و شاخص‌های اقلیمی
۵	۳.۴ ریاضیات متغیرها و رمزگذاری زمانی
۵	۵ روش‌شناسی و الگوریتم‌ها
۵	۱.۵ چرا الگوریتم‌های درختی؟
۶	۲.۵ موتور ترکیبی هوشمند
۶	۶ استراتژی اعتبارسنجی
۶	۱.۶ روش تقسیم متوالی و پنجره لغزان
۷	۲.۶ معیارهای ارزیابی ریاضی
۷	۷ تحلیل نتایج و شواهد
۷	۱.۷ پارادوکس دقت در کوتاه‌مدت
۸	۲.۷ مرز دقت مدل‌های داده‌محور و ضرورت مدل‌های NWP
۸	۸ پیشنهادات و جهت‌گیری‌های آینده

۱ مقدمه و صورت مسئله

۱.۱ زمینه و انگیزه پژوهش

توسعه مدل‌های پیش‌بینی هوا به طور سنتی در انحصار مدل‌های عددی پیش‌بینی هوا (NWP) بود که با حل معادلات دیفرانسیل پیچیده جو کار می‌کنند. با ظهور یادگیری ماشین، این پرسش علمی مطرح شد که "آیا مدل‌های داده‌محور (Data-Driven) می‌توانند با تکیه صرفاً بر داده‌های تاریخی و الگوهای آماری، جایگزین یا رقیب مدل‌های فیزیکی شوند؟" هدف اصلی این پژوهش، نه صرفاً ساخت یک ابزار پیش‌بینی، بلکه **مقایسه و ارتقای مدل‌های هوش مصنوعی و آماری** است تا مشخص شود حداکثر دقت قابل دستیابی بدون دخالت مدل‌های NWP چقدر است و سیستم در کدام بخش‌ها و افق‌های زمانی دچار ناتوانی می‌شود.

۲.۱ صورت مسئله و چالش‌های مدل‌های داده‌محور

مسئله ما، پیش‌بینی متغیرهای جوی (مانند دما) برای ۵ کلان‌شهر ایران در دو افق کوتاه‌مدت (۲۴ ساعته) و میان‌مدت (۷ روزه) با استفاده از ۱۱ مدل مختلف است. در مسیر ارتقای این مدل‌ها، متوجه شدیم که تکیه صرف بر الگوریتم‌های یادگیری ماشین (مانند XGBoost یا LightGBM) در غیاب فیزیک اتمسفری، با چالش‌های بنیادین روبرو است:

۱. **سقف دقت در کوتاه‌مدت:** مدل‌های ML به دلیل درک همخطی بین متغیرهای تأخیری (Lags)، در افق ۲۴ ساعت عملکرد فوق‌العاده‌ای دارند و می‌توانند با NWP رقابت کنند.

۲. **فروپاشی در افق دور (جایی که به NWP نیاز داریم):** به محض عبور از افق ۴۸ ساعت، مدل‌های درختی به دلیل عدم توانایی در برون‌یابی روند (Extrapolation) و انباشت خطا در پیش‌بینی بازگشتی، دچار سقوط شدید دقت می‌شوند و خطوط پیش‌بینی آن‌ها به سمت مقادیر ثابت یا غیرفیزیکی میل می‌کند (Flat-line Collapse).

۳.۱ رویکرد سیستم: ارتقا تا مرز فیزیک


برای پاسخ به این چالش‌ها و کشف مرزهای مدل‌های داده‌محور، ما یک معماری چندلایه طراحی کردیم:

- **ارتقای الگوریتم‌های ML:** برای جلوگیری از فروپاشی مدل‌ها در ۷ روز آینده، استراتژی پیش‌بینی بازگشتی به **Direct Multi-Horizon** (مدل‌سازی مستقل برای هر روز) تغییر یافت. همچنین از تکنیک **Anomaly Targeting** (پیش‌بینی انحراف از میانگین اقلیمی) استفاده شد تا بار یادگیری فیزیک فصل‌ها از دوش مدل برداشته شود.

- **ترکیب نهایی با NWP (MOS Blending):** پس از اعمال تمامی روش‌های ارتقای ML، پذیرفتیم که مدل‌های داده‌محور در افق‌های میان‌مدت به سقف خود می‌رسند. به همین دلیل، Open-Meteo (به عنوان نماینده مدل NWP) را نه به عنوان رقیب، بلکه به عنوان یک ویژگی (Feature) با خروجی ML خودمان ترکیب کردیم (MOS Blending).

۲ نمای کلی سامانه

پیش از ورود به جزئیات فنی، این بخش یک نمای کلی از رابط کامل داشبورد پیاده‌سازی شده ارائه می‌دهد: صفحه اصلی، منوی ناوبری کناری با ۶ بخش، و آمار واقعی ثبت‌شده برای هر شهر.



شکل ۱: نمای کلی اپلیکیشن که نمایش‌دهنده بخش‌های مختلف سامانه است.

ایستگاه	تعداد روز	از	تا	فیلدین دما	MIN/MAX	رطوبت میانگین	کل بارش
اصفهان	2,080	2020-12-31	2026-09-10	C* 18.1	35.5 / 4.8-	% 30.9	mm 668.1
مشهد	2,080	2020-12-31	2026-09-10	C* 15.8	33.9 / 12.7-	% 45.7	mm 1136
شیراز	2,080	2020-12-31	2026-09-10	C* 19.3	34 / 0.3-	% 34.5	mm 1101
تبریز	2,080	2020-12-31	2026-09-10	C* 13.6	31.6 / 11.3-	% 50.5	mm 1972.1
تهران	2,080	2020-12-31	2026-09-10	C* 19.3	37.7 / 1.5-	% 33.1	mm 1340.6

شکل ۲: آمار واقعی ۵ ایستگاه هواشناسی سامانه.

کد منبع و فایل‌های اجرایی این سامانه به صورت متن‌باز در مخزن گیت‌هاب پروژه در دسترس عموم قرار گرفته است:

https://github.com/ebrahimMahdiyeh/Shiny_weather_app

۳ الزامات سیستم (System Requirements)

برای اجرای پایدار خطلوله مقایسه و ارتقای مدل‌ها، سیستم باید الزامات سخت‌گیرانه‌ای را در دو سطح عملکردی و غیرعملکردی برآورده سازد.



شکل ۳: روش‌شناسی پژوهش در ۵ گام.

۱.۳ الزامات عملکردی (Functional Requirements)

- دریافت و همگون‌سازی داده: فراخوانی هم‌زمان دو End-point آرشیو و پیش‌بینی Open-Meteo.
- بازسازی پیوستگی زمانی: ساخت یک توری زمانی ساعتی کامل و بدون حفره.
- مهندسی ویژگی: محاسبه لگ‌های ۱ تا ۷۲ ساعته و رمزگذاری سینیوسی-کوسینیوسی چرخه‌های زمانی.
- پشتیبانی چندگانه از افق پیش‌بینی: روش بازگشتی برای افق ۲۴ ساعته و روش مستقیم برای افق ۷ روزه.

۲.۳ الزامات غیرعملکردی (Non-Functional Requirements)

- تضمین عدم نشت داده: تقسیم داده کاملاً زمانی و متوالی.
- مدیریت حافظه و کارایی: استفاده از ساختارهای ماتریسی بهینه.
- پایداری در برابر خطا: احاطه تمام فراخوانی‌های مدل با مدیریت خطا.
- قیود فیزیکی و اصلاح نویز: حذف داده پرت با تکنیک IQR ماهانه.

۴ مدل داده و مهندسی ویژگی

یکی از چالش‌های اصلی در استفاده از مدل‌های یادگیری ماشین، درک مفاهیم فیزیکی توسط این مدل‌هاست.

۱.۴ پاک‌سازی پیشرفته و حذف نویز

داده‌های خام هواشناسی معمولاً حاوی نویزهای ناشی از خطای سنسورها هستند.

- درون‌یابی خطی: برای گپ‌های کوچک زمانی، سیستم از `na.approx` استفاده می‌کند.
- حذف داده‌های پرت با IQR ماهانه: سیستم به صورت پویا، داده‌ها را بر اساس «ماه» گروهبندی کرده و بازه بین چارک اول و سوم را محاسبه می‌کند. هر دمایی که از بازه $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$ خارج باشد، به عنوان نویز شناسایی می‌شود.

۲.۴ قیود فیزیکی و شاخص‌های اقلیمی

برای کمک به مدل‌های درختی تا منطق فیزیکی جو را درک کنند، ویژگی‌های جدیدی ساخته شدند:

- **قید منطقی** ($T_{min} \leq T_{max}$): سیستم پس از پیش‌بینی مقادیر بیشینه و کمینه، یک لایه ایمنی ریاضی اعمال می‌کند.
- **تقریب تابش خورشید** (solar_rad): شدت تابش خورشید را با فرمول مثلثاتی مدل کردیم:

$$\theta = \sin \left(2\pi \frac{H - \phi}{24} \right) \quad (1)$$

که در آن H ساعت روز است. مقادیر منفی صفر در نظر گرفته شده و در یک ضریب تصحیح فصلی ضرب می‌شوند.

$$\left(1 + \cos \left(\frac{2\pi(D-172)}{365} \right) \right)$$

۳.۴ ریاضیات متغیرها و رمزگذاری زمانی

زمان یک متغیر چرخه‌ای است. مثلاً ساعت ۲۳ بسیار به ساعت ۰۰ نزدیک‌تر است تا به ساعت ۱۲.

- **رمزگذاری سینوسی-کوسینوسی**: سیستم برای حفظ پیوستگی ریاضی حلقه‌های زمانی، ساعت و روز سال را به مختصات دکارتی تبدیل می‌کند:

$$X_{hour} = \sin \left(2\pi \frac{hour}{24} \right), \quad Y_{hour} = \cos \left(2\pi \frac{hour}{24} \right) \quad (2)$$

- **متغیرهای تاخیری (Time Lags)**: برای اینکه مدل بتواند روند را ببیند، مقادیر گذشته متغیر هدف به عنوان ویژگی‌های جدید ساخته می‌شوند.
- **آمار لغزان**: سیستم میانگین متحرک و انحراف معیار متحرک را محاسبه می‌کند تا مدل میزان نوسانات اخیر را درک کند.

۵ روش‌شناسی و الگوریتم‌ها

در این سامانه، ۱۱ مدل مختلف در دو خانواده اصلی آماری و یادگیری ماشین پیاده‌سازی شده‌اند.

۱.۵ چرا الگوریتم‌های درختی؟

مدل‌های مبتنی بر درخت تصمیم، در سال‌های اخیر به ستاره‌های پیش‌بینی سری‌های زمانی تبدیل شده‌اند.

- **مقاومت در برابر هم‌خطی شدید**: مدل‌های درختی ذاتاً به هم‌خطی مقاوم هستند.
- **درک تعاملات غیرخطی**: مدل‌های درختی می‌توانند روابط پیچیده‌ای را درک کنند.
- **چالش برون‌یابی**: تنها ضعف ذاتی این مدل‌ها این است که نمی‌توانند مقادیر بزرگتر از محدوده آموزشی خود را پیش‌بینی کنند.

۲.۵ موتور ترکیبی هوشمند

سیستم یک لایه ترکیبی طراحی کرده است:

۱. فیلتر مدل‌های ضعیف: مدلی که خطای آن بسیار بالاست حذف می‌شود.

۲. وزن‌دهی نرم: به مدل‌های قوی‌تر وزن بیشتری داده می‌شود:

$$w_i = \frac{e^{-\beta \cdot RMSE_i}}{\sum e^{-\beta \cdot RMSE_j}} \quad (۳)$$

۳. ترکیب خروجی: پیش‌بینی نهایی، میانگین وزنی خروجی مدل‌های قوی است.

۶ استراتژی اعتبارسنجی

اعتبارسنجی در پروژه‌های سری زمانی با یادگیری ماشین سنتی کاملاً متفاوت است.

۱.۶ روش تقسیم متوالی و پنجره لغزان

- منع نمونه‌گیری تصادفی: تقسیم داده‌ها به صورت ۱۰۰٪ متوالی انجام می‌شود.
- تحلیل پایداری در پنجره‌های زمانی: داده‌های آزمون به ۳ پنجره زمانی مجزا تقسیم می‌شوند و "انحراف معیار رتبه‌بندی" محاسبه می‌شود.



شکل ۴: خروجی واقعی سامانه برای تحلیل پایداری رتبه‌بندی مدل‌ها.

۲.۶ معیارهای ارزیابی ریاضی

برای مقایسه ۱۱ مدل، سیستم به یک معیار واحد اتکا ندارد.

• RMSE (جذر میانگین مربعات خطا):

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (۴)$$

• MAE (میانگین قدر مطلق خطا):

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (5)$$

• R^2 (ضریب تعیین): نشان می‌دهد که مدل ما چقدر توانسته واریانس داده‌ها را توضیح دهد.

۷ تحلیل نتایج و شواهد


پس از اجرای پایپ‌لاین کامل و ارزیابی ۱۱ مدل بر روی ۵ کلان‌شهر ایران، نتایج به دست آمده شواهد روشنی از نقاط قوت و ضعف الگوریتم‌های داده‌محور ارائه می‌دهد.

۱.۷ پارادوکس دقت در کوتاه‌مدت

یکی از شگفت‌انگیزترین نتایج بنچمارک ۲۴ ساعته، رقابت بسیار نزدیک مدل‌های پیچیده با ساده‌ترین مدل موجود، یعنی Naïve بود.

• **دلیل علمی:** جرم هوا در یک منطقه در کوتاه‌مدت به سرعت تغییر نمی‌کند.

• **نتیجه:** مدل‌های ML به سختی توانستند از مدل Naïve پیشی بگیرند.



شکل ۵: نمای واقعی پیش‌بینی ۲۴ ساعته اصفهان در داشبورد

۲.۷ مرز دقت مدل‌های داده‌محور و ضرورت مدل‌های NWP

شواهد نشان داد:

• **افق ۱ تا ۳ روز:** مدل‌های داده‌محور کاملاً مستقل هستند و می‌توانند با دقت بالا ($R^2 > 0.90$) با مدل‌های NWP رقابت کنند.

• **افق ۴ تا ۷ روز:** تغییرات جبهه‌های هوایی باعث می‌شود دقت ML به شدت افت کند.

• **راه‌حل نهایی:** با میانگین‌گیری ۵۰-۵۰ بین خروجی ML و Open-Meteo، توانستیم یک پیش‌بینی پایدار تولید کنیم.



شکل ۶: پیش‌بینی ۷ روزه به تفکیک هر روز در داشبورد.

نتیجه‌گیری نهایی گزارش

این پروژه نشان داد که یادگیری ماشین جایگزین مطلق فیزیک اتمسفری نیست؛ بلکه مکمل آن است.

۸ پیشنهادات و جهت‌گیری‌های آینده

با توجه به یافته‌های این پژوهش، مسیرهای زیر پیشنهاد می‌شود:

- بهره‌گیری از مدل‌های یادگیری عمیق: افزودن معماری‌هایی مانند LSTM.
- وزن‌دهی پویا در موتور ترکیبی: به‌روزرسانی وزن‌ها بر اساس عملکرد اخیر هر مدل.
- پیش‌بینی احتمالاتی: ارائه بازه‌های اطمینان به جای یک عدد قطعی.